

# Algorithme de détection de la race du chien sur une photo



OPENCLASSROOMS

colab  
kaggle

Android  
Studio

# Outline

- **Introduction**
  - Objectif de l'étude
  - Jeux de données
- **Feature engineering**
  - Traitement des images
  - Augmentation
- **Modélisation**
  - Modelés simples – numéro réduit des races
  - Transfer-learning et batch processing (modélisation complète)
  - Optimisation du modèle (couches denses, vitesse apprentissage)
  - Tensorflow-lite model maker : peu de code et petite taille
- **Conclusions**
  - Choix du modèle (serveur web/ smartphone)

## Modalités de la soutenance

5 min - Présentation de la problématique, de son interprétation et des pistes de recherche envisagées.

5 min - Présentation du cleaning effectué, du feature engineering et de l'exploration.

10 min - Présentation des différentes pistes de modélisation effectuées.

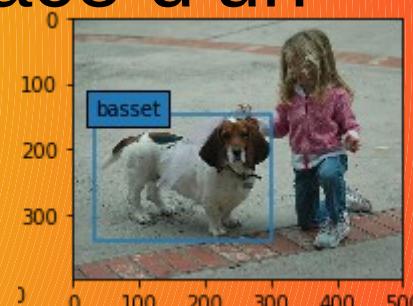
5 min - Présentation du modèle final sélectionné et résultats.

5 à 10 minutes de questions-réponses.

# Objectif du modèle

Dans cette étude avec un apprentissage supervisé, on utilise une réseaux des neurones convolutionelle pour

- Déterminer précisément ( $P > 80\%$ ) la race d'un chien à partir d'une photo
- Intégrer une application sur un smartphone (taille < 20 MB) ou site web



# Données du départ

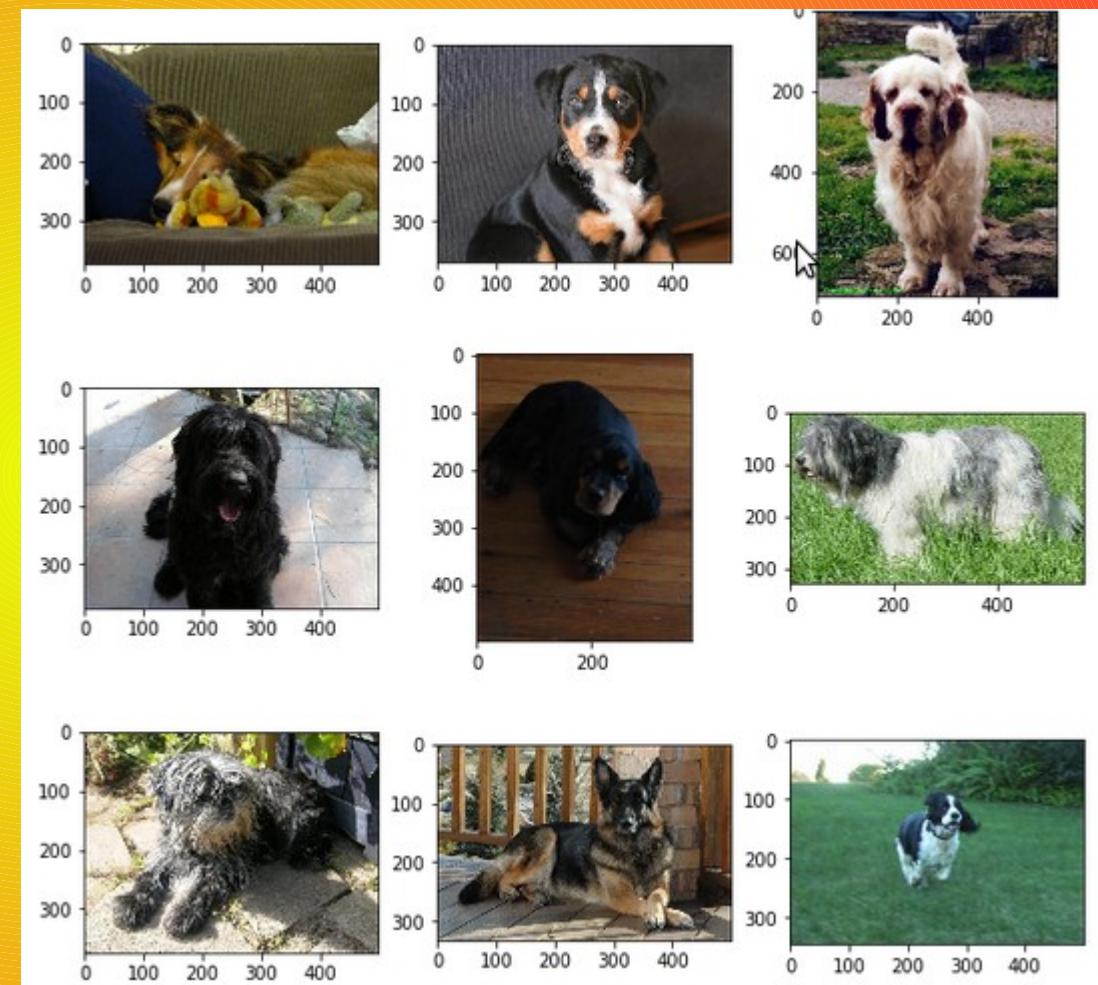
Data Explorer

751.55 MB

- annotations
- Annotation
- images
- Images

< Images (120 directories)

n02085620-Chihuahua 152 files	n02085782-Japanese_... 185 files
n02086240-Shih-Tzu 214 files	n02086646-Blenheim_... 188 files



On a des annotations  
mais aussi le nom de la  
race pour chaque  
dossier d'image

# Pre-traitement des données

- Equalisation
- Augmentation des images
- Réduction de la taille (format pour réseaux neurones)
- Segmentation des données : entraînement, test

# Pre-traitement des données

Réduction à la taille adaptée  
pour une réseaux des neurones

Observations X

```
#resize image to 227 x 227 because the input
resized_img = img_array.resize((227, 227))

img_lst.append(np.array(resized_img))

labels.append(filtered_breeds[index])
```

Normalisation

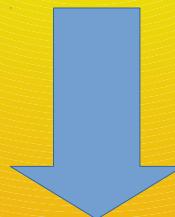
```
#Normalization for the images
images = np.array(images)
images = images.astype(np.float32)
#labels = labels.astype(np.int32)
X_norm = images/255
```



One-hot-encoding pour les categories

Cible y

```
# replace numbers with names
le = LabelEncoder()
nlabels = le.fit_transform(labels) # encode labels as number values. This
Y=to_categorical(nlabels,num_classes = num_breeds) # category encoding
```

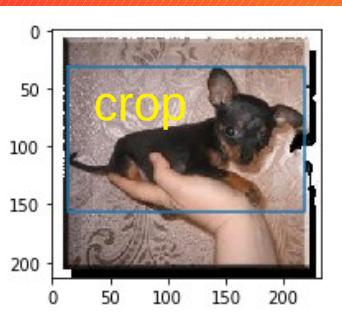


Données Entraînement, validation , test

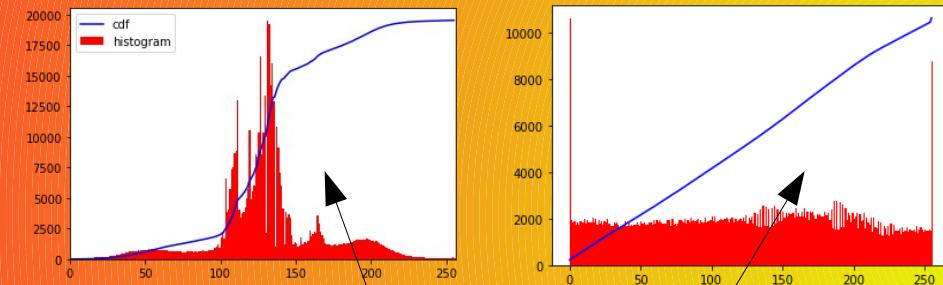


```
x_train, x_test, y_train, y_test = train_test_split(X_norm, Y, test_size = 0.2, random_state = 42)
x_train, x_val, y_train, y_val = train_test_split(x_train, y_train, test_size=0.1, random_state=1)
```

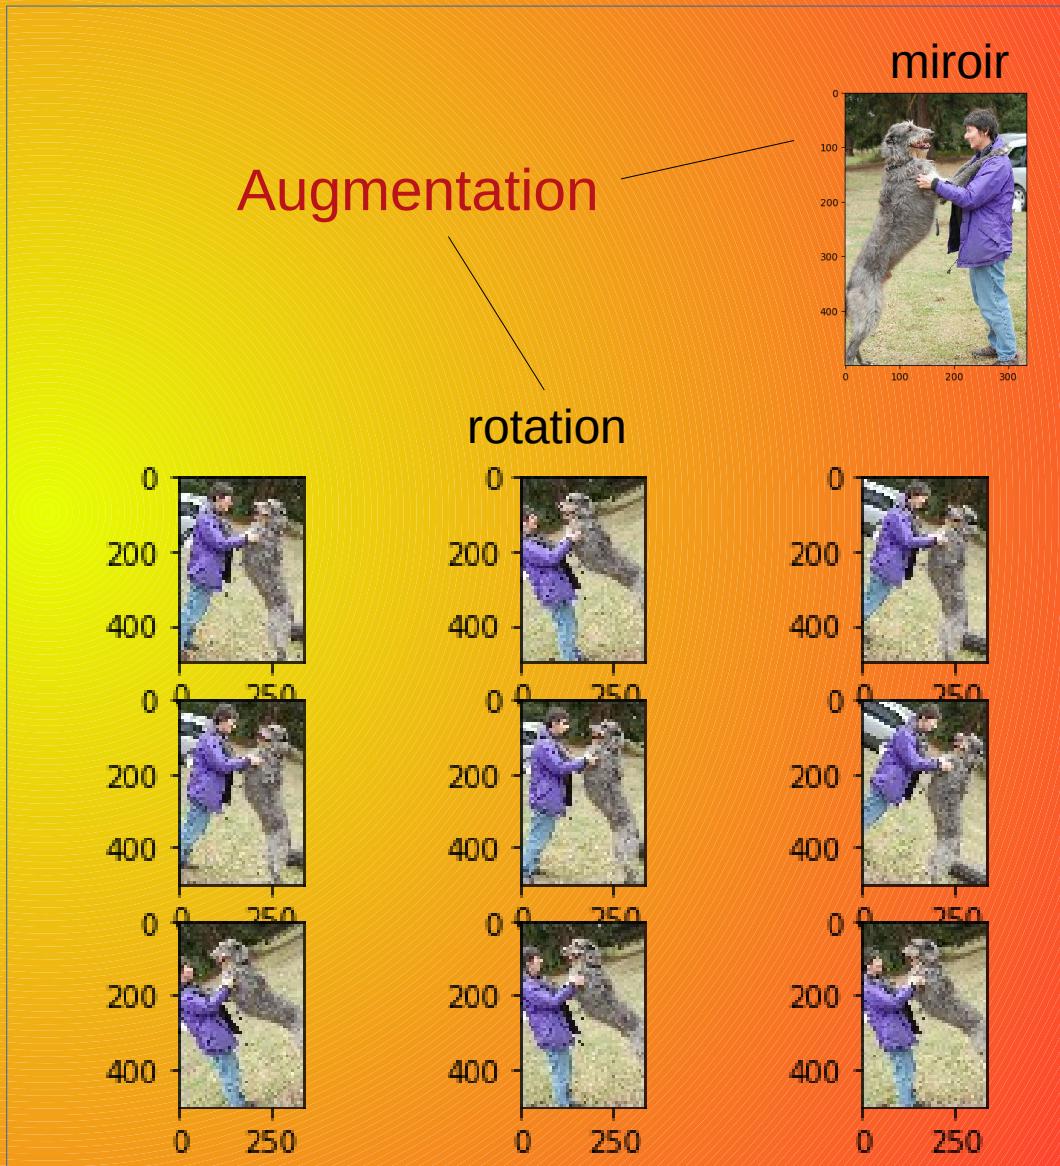
# Pre-traitement des images



Equalisation

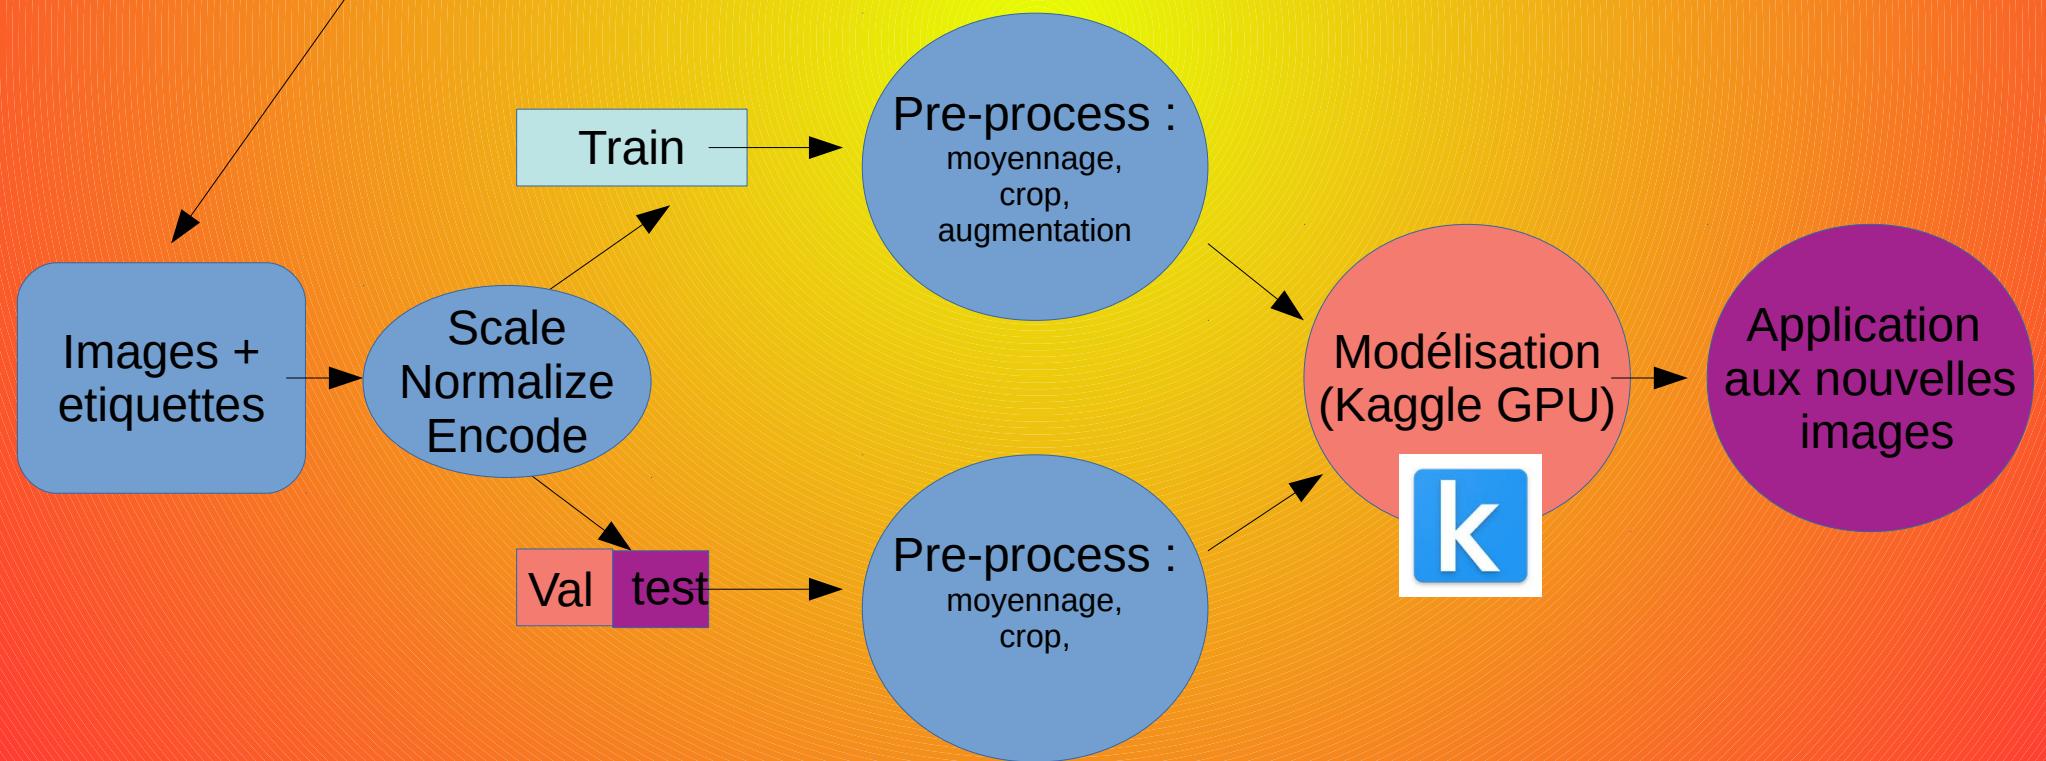


Augmentation



Que pour les données d'entraînement  $X_{\text{train}}$

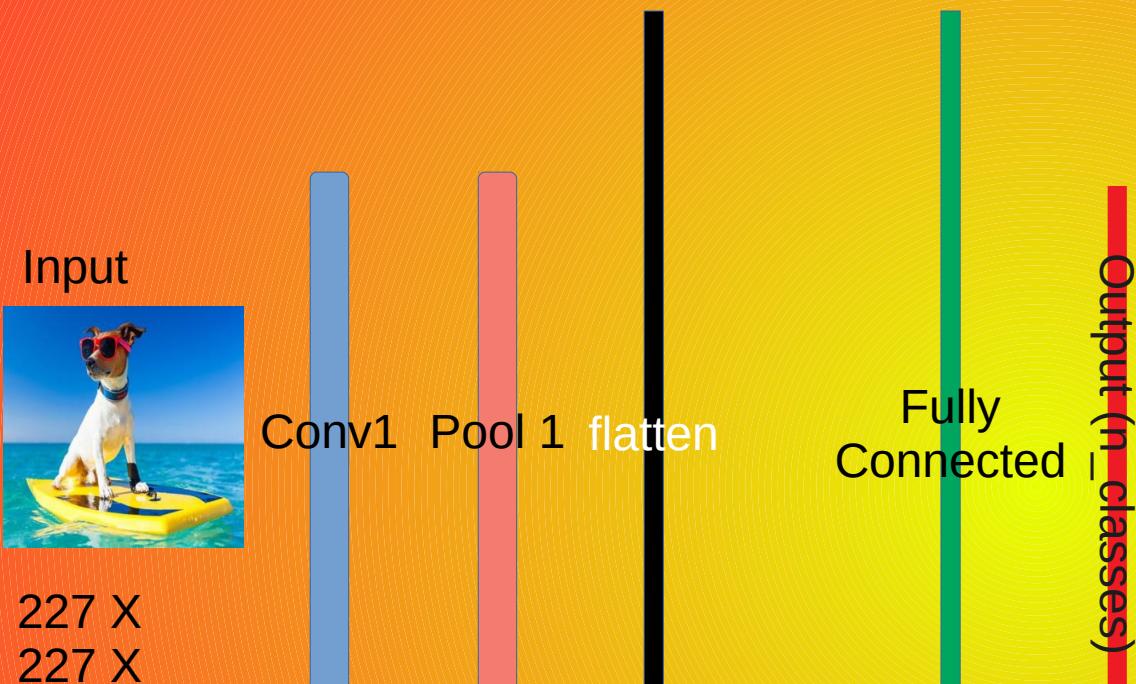
# Batch processing



# Modélisation des données

- Simple multi-layer perceptron
- Alexnet
- Xception transfer learning

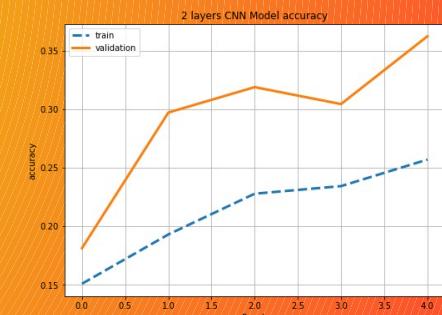
# Modèle 0 : 2-couches CNN



Features extraction

Classification

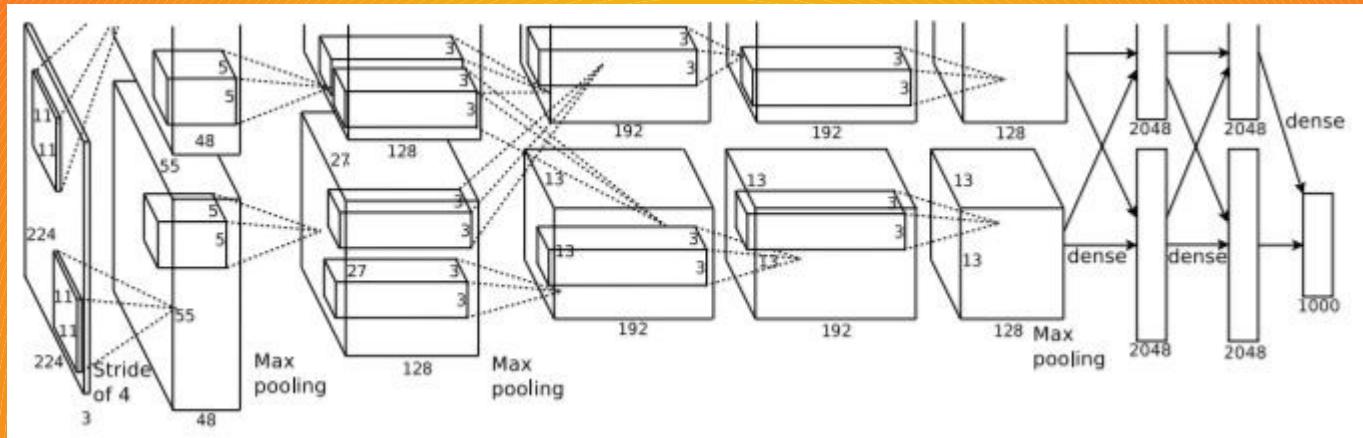
Model: "sequential"		
Layer (type)	Output Shape	Param #
conv2d (Conv2D)	multiple	432
max_pooling2d (MaxPooling2D)	multiple	0
flatten (Flatten)	multiple	0
dropout (Dropout)	multiple	0
dense (Dense)	multiple	6654080
dense_1 (Dense)	multiple	1290
Total params: 6,655,802 Trainable params: 6,655,802 Non-trainable params: 0		



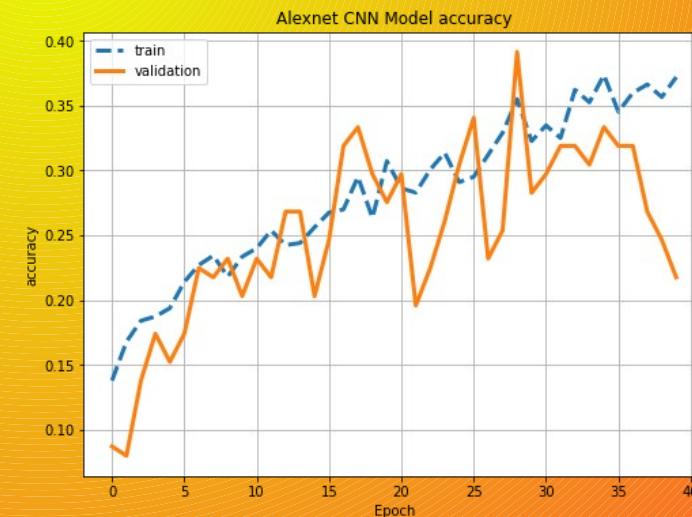
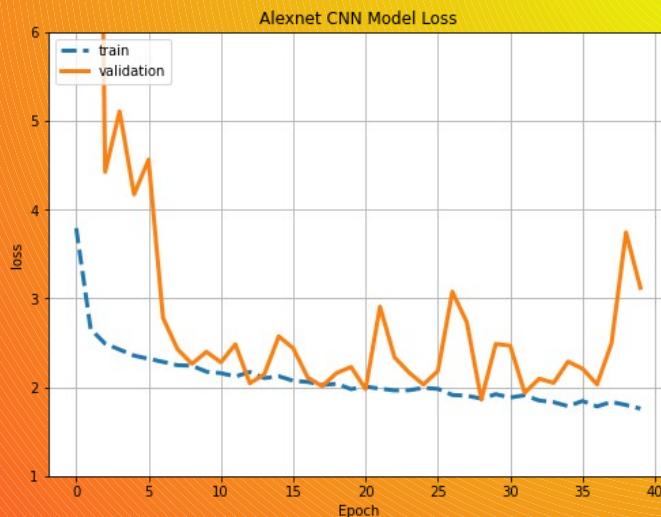
Underfitting

Test accuracy : 34 %

# Modèle 1 : Alexnet



Avec plus des couches on essaye de réduire l'underfitting



Précision faible : 23 %



# Résultats Alexnet

affenpinscher



black-and-tan\_coonhound 50%, affenpinscher 50%, Lakeland\_terrier 0%

Lakeland\_terrier



silky\_terrier 60%, affenpinscher 30%, Lakeland\_terrier 0%

whippet



affenpinscher 80%, black-and-tan\_coonhound 10%, Lakeland\_terrier 0%

whippet



affenpinscher 100%, Lakeland\_terrier 0%, wire-haired\_fox\_terrier 0%

whippet



affenpinscher 60%, Weimaraner 40%, Lakeland\_terrier 0%

wire-haired\_fox\_terrier



black-and-tan\_coonhound 30%, papillon 20%, affenpinscher 20%

silky\_terrier



silky\_terrier 100%, Lakeland\_terrier 0%, wire-haired\_fox\_terrier 0%

black-and-tan\_coonhound



black-and-tan\_coonhound 50%, affenpinscher 30%, silky\_terrier 10%

Weimaraner



Weimaraner 50%, whippet 40%, affenpinscher 10%

Parfois correct

# Transfer learning : Xception

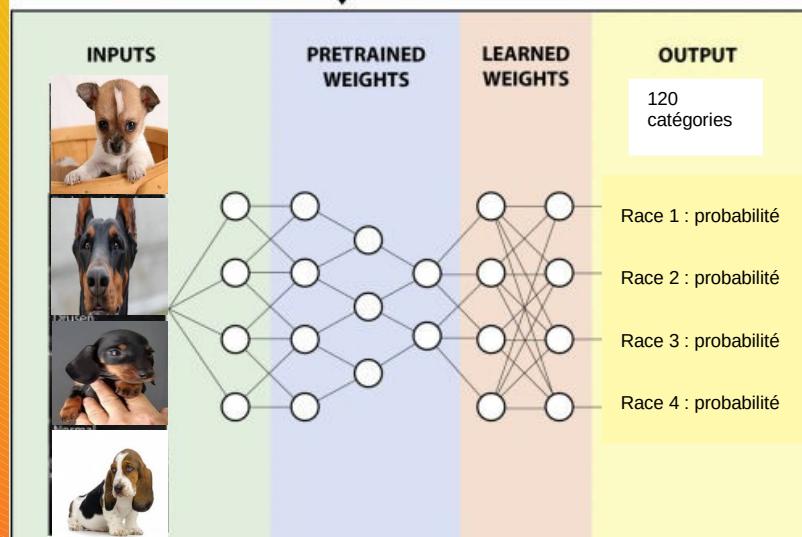
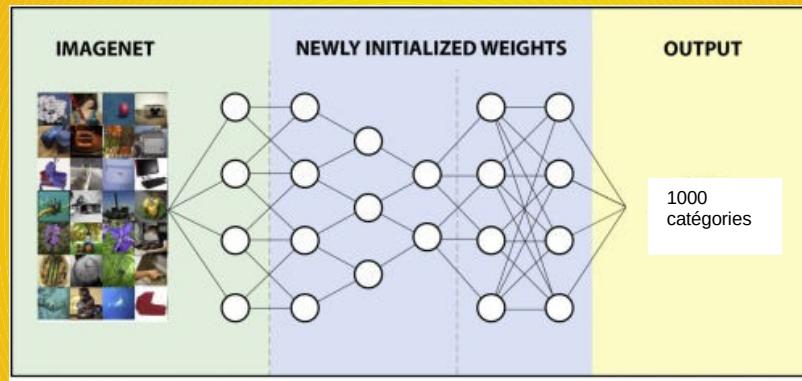
VGGNet – 1<sup>st</sup> Runner Up in ILSVRC 2014  
ResNet – Winner in ILSVRC 2015  
Inception-v3 – 1<sup>st</sup> Runner Up in ILSVRC 2015

	Top-1 accuracy	Top-5 accuracy
VGG-16	0.715	0.901
ResNet-152	0.770	0.933
Inception V3	0.782	0.941
Xception	<b>0.790</b>	<b>0.945</b>

Pourquoi Xception ?

Include top  
= False

Trainable = False



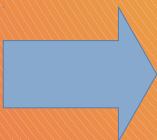
# Transfer learning architecture

Model: "sequential\_1"

Layer (type)	Output Shape	Param #
xception (Functional)	(None, 2048)	20861480
dense_3 (Dense)	(None, 1032)	2114568
dense_4 (Dense)	(None, 512)	528896
dense_5 (Dense)	(None, 256)	131328
dense_6 (Dense)	(None, 120)	30840
<hr/>		
Total params: 23,667,112		
Trainable params: 2,805,632		
Non-trainable params: 20,861,480		

Include top  
= False

Input



Xception :  
weights pretrained  
with Imagenet

```
Downloading data from https://storage.googleapis.com/tensorflow/keras-applications/xception/xception_weights_tf_dim_ordering_tf_kernels_notop.h5  
83689472/83683744 [=====] - 1s 0us/step
```

flatten

Classification

Fully  
Connected

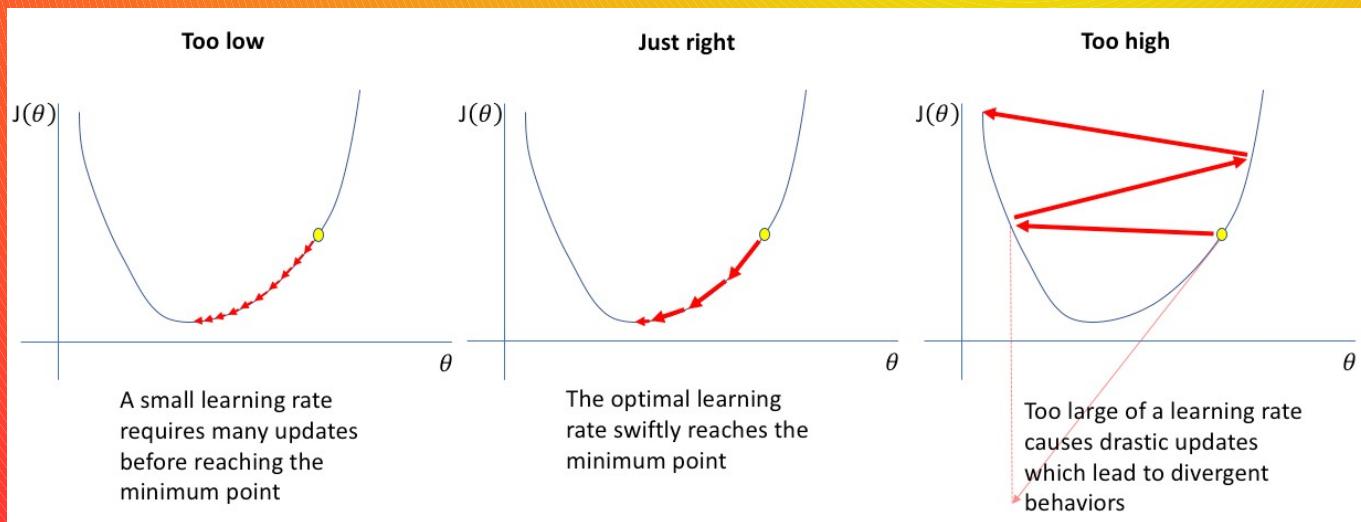
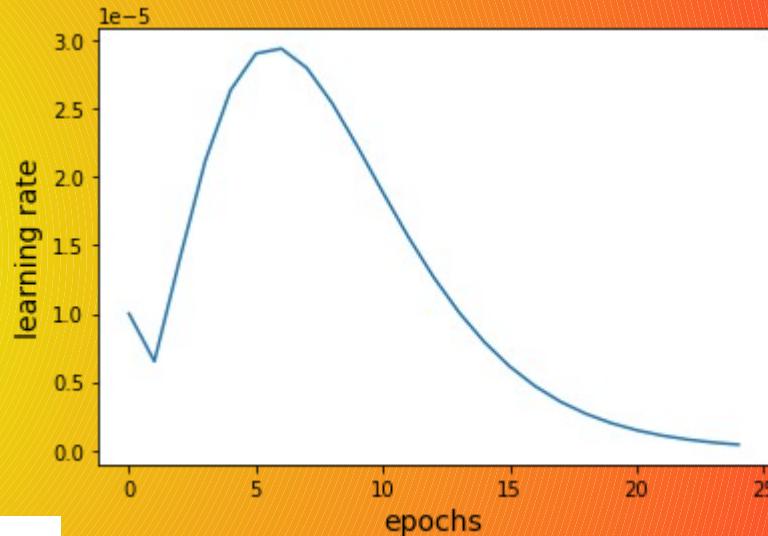


Output (120\_classes)

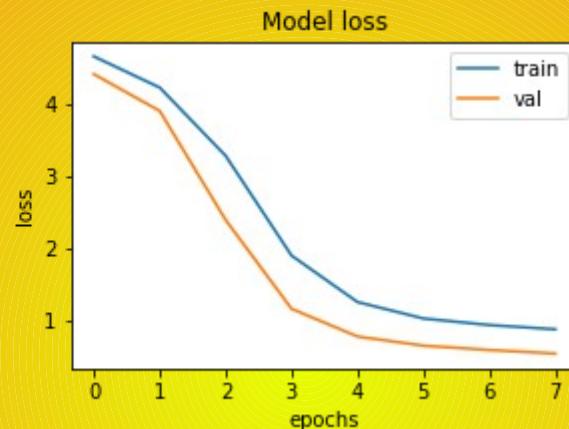
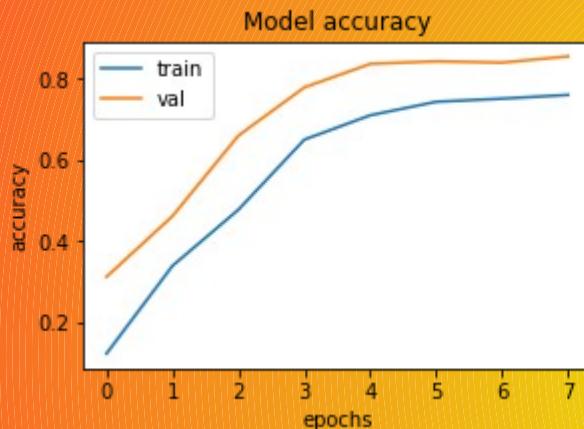
Export trained model :  
my\_model.h5

# Optimisation de l'entraînement

- n couches cachées
- dropout
- n epochs / steps per epoch
- vitesse d'apprentissage  $\alpha$



# Transfer learning : Résultats



Underfitting  
(un peu)

93.55%	malinois
1.69%	kelpie
1.32%	German_shepherd
0.72%	Doberman
0.65%	dingo



```
test_loss, test_accuracy = my_model.evaluate_generator(generator=test_ds, steps=int(100))

print("Test results \n Loss:", test_loss, '\n Accuracy', test_accuracy)
```

```
Test results
Loss: 0.5387319326400757
Accuracy 0.8543750047683716
```

85 %  
accuracy

## Output

543.9 MB

- dog\_breed\_xcept\_weights.h5
- my\_model.h5

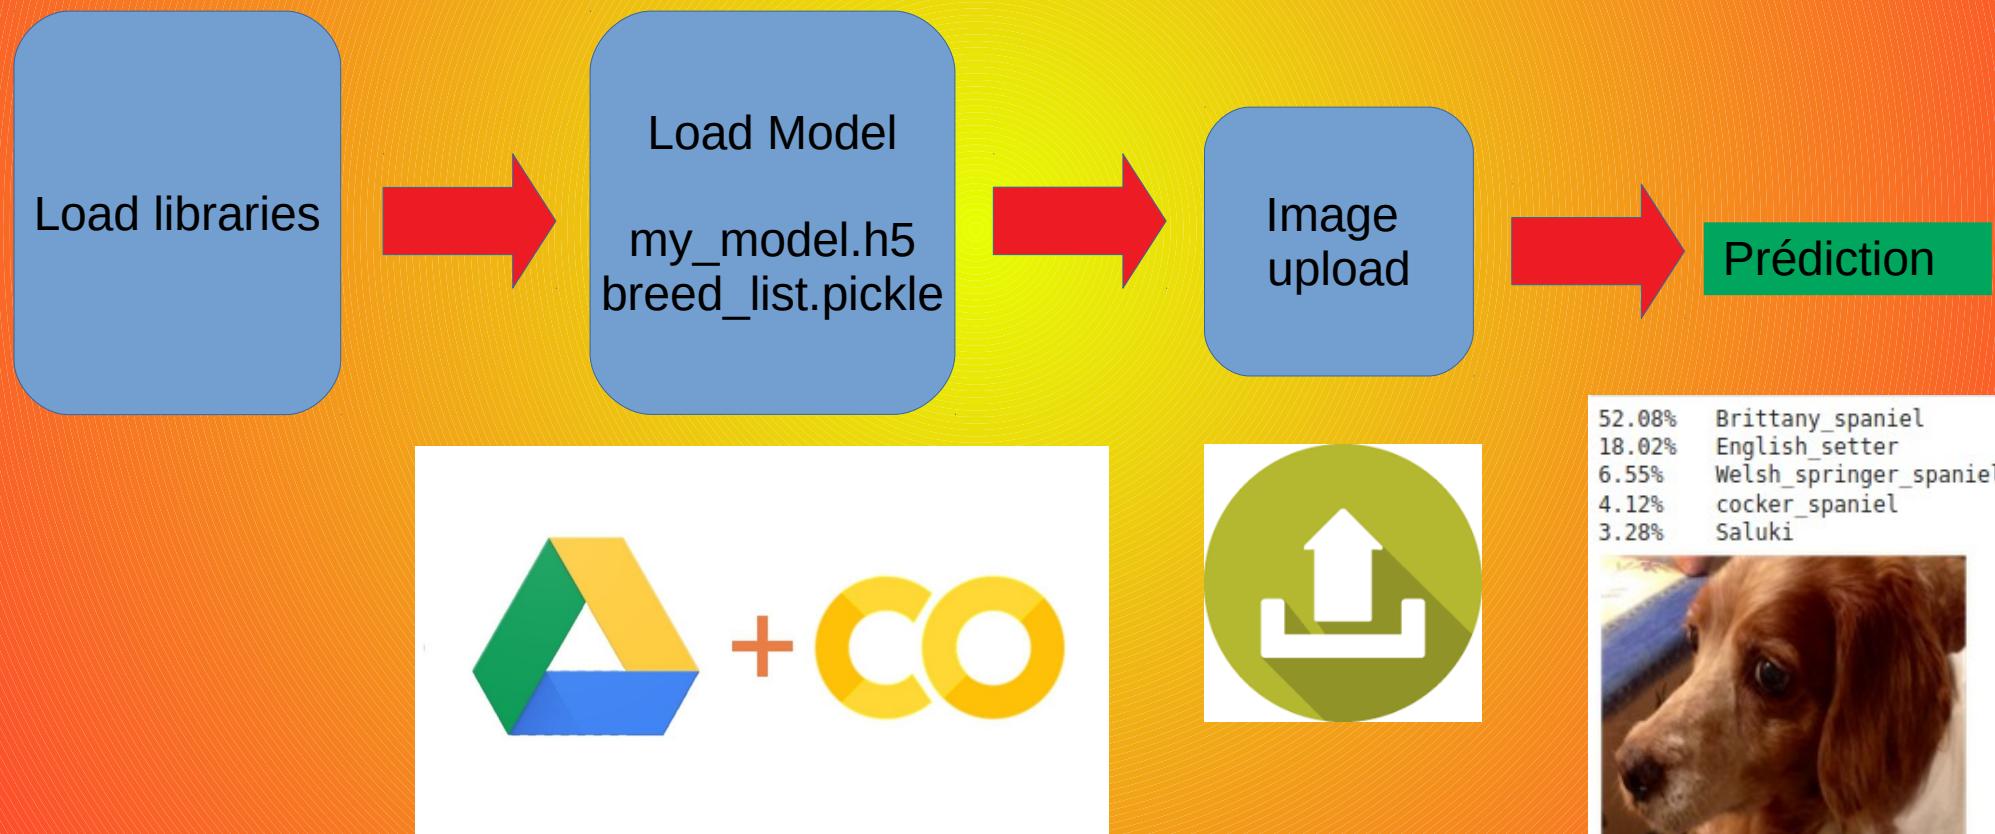
**my\_model.h5 (111.95 MB)**

Modèle sauvé dans un fichier assez petit pour un serveur web mais trop lourd pour un smartphone

```
download_and_predict("https://cdn.pixabay.com/photo/2018/08/12/02/52/belgian-malinois-3599991_1280.jpg",
                      "test_1.jpg")
```

# Classification : modèle pré-entraîné

[https://colab.research.google.com/drive/1kcAFOSreOd\\_68WF5gdvoQOceld7cAwrX](https://colab.research.google.com/drive/1kcAFOSreOd_68WF5gdvoQOceld7cAwrX)



Script sur Google  
Colabs

# Développent pour Android

- Presque pas des réglage
- Précis (85%)
- Léger (smartphone app, pas des serveurs)

# Modélisation pour smartphone

Modèle Tensorflow  
Imageclassifier



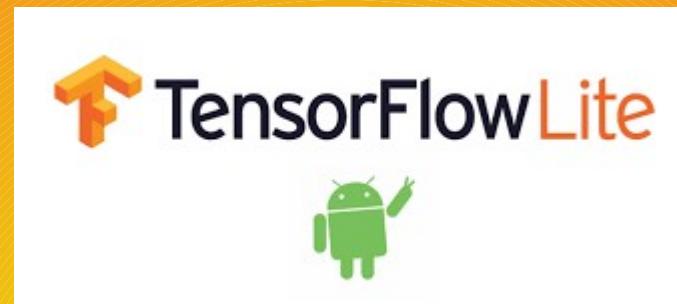
Entraînement sur  
base de données choisie  
(Colabs GPU)



Tensorflow-Lite  
converter



Model file  
(.tflite)



# Conclusions

- Les modèles multi-couche perceptron donnent underfitting et faible précision
- Le meilleur résultat était obtenu avec une réseaux plus complexe et une optimisation des paramétrés(vitesse apprentissage...)
- Avec Tensorflow-lite model maker un modèle très léger mais performant était crée pour Android